

Especificação Técnica: Copiloto Hermes

Módulo Conversacional e RAG Híbrido | Data: 14 de Abril de 2026

1. Visão Geral

O Copiloto Hermes é a interface de inteligência artificial projetada para atuar como um consultor estratégico sobre o Grafo de Conhecimento e o Acervo Global da instituição. Ele substitui buscas estáticas por uma experiência de diálogo analítico.

2. Engenharia de Prompt (System Instructions)

O modelo deve ser configurado com o seguinte prompt de sistema para garantir objetividade e proatividade:

```
IDENTIDADE: Estrategista sênior de processos Hermes.  
TOM DE VOZ: Analítico, direto, conciso. Use bullet points.  
MECÂNICA CORE:  
- SEMPRE use 'consultar_historico_acoes' e 'buscar_arquivos_acervo' antes de concluir.  
- CONFLITOS: Se a prática (Grafo) divergir da teoria (Acervo), exponha ambos.  
- CITAÇÕES: Use [1], [2] para referenciar IDs de tarefas ou documentos.  
- REGRA DE OURO: Nunca encerre sem propor uma ação, checklist ou alerta de risco.
```

3. Definição de Ferramentas (Functions)

- **consultar_historico_acoes(query, tags):** Busca semântica no Grafo de Conhecimento (Firestore knowledge_nodes).
- **buscar_arquivos_acervo(query):** Busca vetorial (Firestore Vector Search) no índice plano de artefatos.
- **obter_contexto_tela(task_id):** Recupera dados da tarefa ativa para "consciência de tela".

4. Interface e Experiência do Usuário

Acesso e Layout

O chatbot será acessado pelo primeiro botão do menu de atalhos lateral. A interface deve ser um **Side Drawer** persistente que não oculte o conteúdo principal da tela.

Payload de Inicialização

Sempre que o atalho for acionado, o frontend deve capturar o estado da rota atual e enviar o ID da Tarefa ativa no primeiro "turno" invisível da conversa para garantir relevância imediata.

5. Gestão de Contexto e Segurança

- **Circuit Breaker:** Limite total de 8.000 tokens.
- **Priorização:** 75% da janela para dados do Grafo (Prática) e 25% para o Acervo (Teoria).
- **Poda:** Descarte de documentos do acervo menos relevantes em caso de estouro de tokens.

